Python para Ciência de Dados

Reticulate

6 de 2022

Motivação

- Já aprendemos muito sobre Python e sobre como configurá-lo
  - Google Colab, notebooks, etc.
  - Instalação local, Conda, Virtualenv, etc.
  - PyCharm, VS Code, etc.
- Mas não queremos jogar fora o nosso conhecimento de R!
  - Não precisa de Conda/Virtualenv e funciona no RStudio
  - Será possível unir o útil ao agradável?
- Queremos:
  - Aproveitar código Python que já existe
  - Continuar usando R onde for mais confortável
  - Não precisar gerenciar ambientes ou trocar de IDE

Introdução

Reticulate

- Reticulate é um pacote com todas as ferramentas necessárias para conectar o R com o Python
  - Chamar o Python pelo R (scripts, módulos, etc.)
  - Traduzir objetos entre o R e o Python
  - Conexão direta com ambientes virtuais (Conda, Virtualenv)
- Muito útil para interoperabilidade entre as duas linguagens
  - Times que usam R e Python
  - Uso de funcionalidades exclusivas à outra linguagem
  - Centralização de workflows
- Basta instalar!

```
install.packages("reticulate")
```

Uso básico

```r
library(reticulate)

# Inicializar o Python do sistema
py_available(initialize = TRUE)
```

```
## [1] TRUE
```

```r
# Verificar versão
py_version()
```

```
## [1] '3.8'
```

```r
# Executar comando Python e pegar resultado no R
py_eval("[1, 2, 3] + [4]")
```

```
## [1] 1 2 3 4
```

Conda e Virtualenv

- O reticulate é capaz de instalar o Miniconda

```
install_miniconda()
```

```
# Versão do Conda instalado pelo Miniconda
conda_version()
```

```
## [1] "conda 4.13.0"
```

- Ele não consegue instalar o Virtualenv, mas consegue usá-lo (só no Mac e no Linux!)

```
# Raíz onde os ambientes do Virtualenv vão ficar
virtualenv_root()
```

```
## [1] "~/.virtualenvs"
```

Usando o ambiente virtual

- Camos fazer tudo no Conda em no ambiente `r-reticulate`
    - A recomendação é não desviar do padrão

```
# Feito uma vez só (= conda create)
conda_create("r-reticulate")

# Rodar no começo de cada sessão (= conda activate)
use_condaenv("r-reticulate")

# Instalar pacote no r-reticulate (= conda install)
py_install("platform")
```

```
# Verificar se o pacote foi instalado
py_module_available("platform")
```

```
## [1] TRUE
```

Uso

Chamando o Python

- Há 4 jeitos de chamar o Python depois de feita a configuração
    - Executar um arquivo inteiro com `source_python()` da mesma forma como faríamos com `source()`
    - Importação direta de módulos dentro do R
    - Dentro do RMarkdown com comunicação bidirecional
    - REPL (Read, Eval, Print Loop) no Console do RStudio
- Todos esses métodos usam o ambiente `r-reticulate` do Conda como padrão
    - No caso de qualquer problema, a função `py_discover_config()` é sua amiga

Import

- A importação ocorre como no Python: um objeto com funções
  - Ao invés do `.`, usamos `$`
  - A síntaxe vira uma mistura de R e Python
  - É possível criar wrappers de pacotes do Python!

```
# Pegar nome da plataforma
platform <- import("platform")
platform$platform()
```

```
## [1] "macOS-12.4-arm64-arm-64bit"
```

```
# Pegar primeiro elemento de uma array do Numpy
np <- import("numpy")
np$array(c(1, 2, 3, 4))[1]
```

```
## [1] 1
```

Conversões

- Código em R e o que ele vira em Python
  - Atenção especial aos índices! No Python eles começam em 0

Exemplo	Python
`1, 1L, TRUE, "foo"`	Escalar
`c(1.0, 2.0, 3.0), c(1L, 2L, 3L)`	Lista
`list(1L, TRUE, "foo")`	Tupla
`list(a = 1L, b = 2.0), dict(x = x_data)`	Dicionário
`matrix(c(1,2,3,4), nrow = 2, ncol = 2)`	NumPy ndarray
`data.frame(x = c(1,2,3))`	Pandas DataFrame
`function(x) x + 1`	Função
`as.raw(c(1:10))`	Python bytearray
`NULL, TRUE, FALSE`	None, True, False

RMarkdown

- Parece um truque de mágica

```
# Código Python normal
obj = [1, 2, 3]
print(obj)
```

```
## [1, 2, 3]
```

```
# Código R normal
obj2 <- py$obj + 1
print(obj2)
```

```
## [1] 2 3 4
```

```
# Código Python normal
r.obj2 + [5.0]
```

```
## [2.0, 3.0, 4.0, 5.0]
```

RMarkdown

- Basta especificar a linguagem no começo do chunk
  - Os objetos do Python ficam acessíveis em `py$x`
  - Os objetos do R ficam acessíveis em `r.x`

````
13
14 ```{python}
15 import pandas
16 flights = pandas.read_csv("flights.csv")
17 flights = flights[flights['dest'] == "ORD"]
18 flights = flights[['carrier', 'dep_delay', 'arr_delay']]
19 flights = flights.dropna()
20 ```
21
22 ```{r, fig.width=7, fig.height=3}
23 library(ggplot2)
24 ggplot(py$flights, aes(carrier, arr_delay)) + geom_point() + geom_jitter()
25 ```
26
````

REPL

- REPL (Read, Eval, Print Loop) é o termo técnico para ferramentas como o "Console" que usamos no R
    - Se abrirmos um arquivo Python no RStudio e rodarmos qualquer linha com CTRL + ENTER, vamos ativar o REPL do Python
    - Ao invés do ">" tradicional, o prompt vira ">>>"
    - Para sair basta rodar o comando `exit` e voltaremos para o R

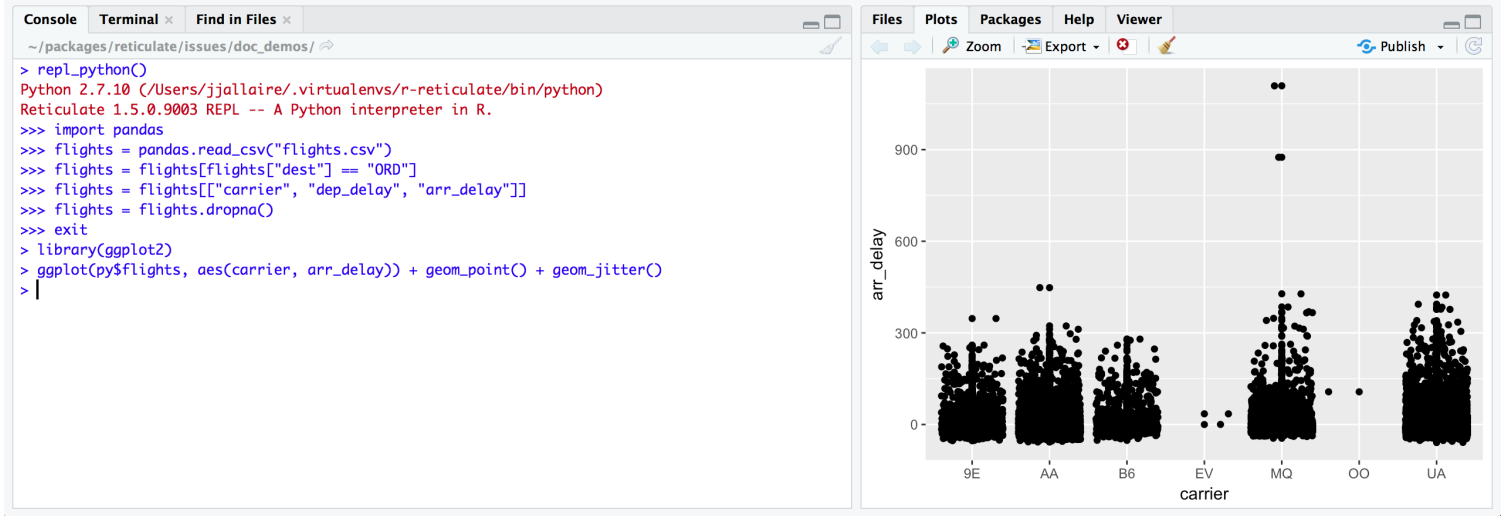

REPL

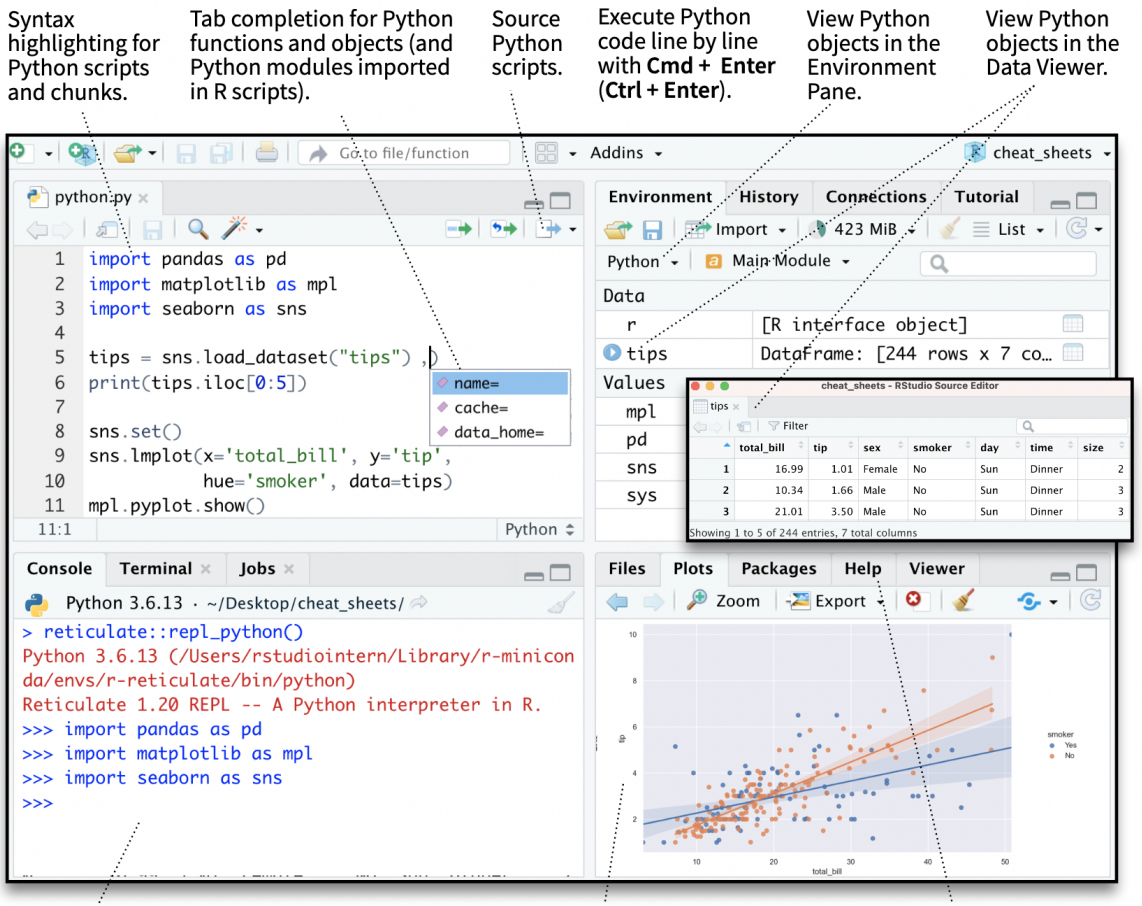
Syntax highlighting for Python scripts and chunks.
Tab completion for Python functions and objects (and Python modules imported in R scripts).
Source Python scripts.
Execute Python code line by line with Cmd + Enter (Ctrl + Enter).
View Python objects in the Environment Pane.
View Python objects in the Data Viewer.
Go to file/function
Addins
cheat_sheets
python.py
import pandas as pd
import matplotlib as mpl
import seaborn as sns
tips = sns.load_dataset("tips") ,)
print(tips.iloc[0:5])
sns.set()
sns.lmplot(x='total_bill', y='tip',
hue='smoker', data=tips)
mpl.pyplot.show()
name=
cache=
data_home=
11:1
Python
Environment
History
Connections
Tutorial
Import
423 MiB
List
Python
Main Module
Data
r
[R interface object]
tips
DataFrame: [244 rows x 7 co…
Values
mpl
pd
sns
sys
cheat_sheets - RStudio Source Editor
Filter
total_bill tip sex smoker day time size
1 16.99 1.01 Female No Sun Dinner 2
2 10.34 1.66 Male No Sun Dinner 3
3 21.01 3.50 Male No Sun Dinner 3
Showing 1 to 5 of 244 entries, 7 total columns
Console
Terminal
Jobs
Python 3.6.13 · ~/Desktop/cheat_sheets/
> reticulate::repl_python()
Python 3.6.13 (/Users/rstudiointern/Library/r-miniconda/envs/r-reticulate/bin/python)
Reticulate 1.20 REPL -- A Python interpreter in R.
>>> import pandas as pd
>>> import matplotlib as mpl
>>> import seaborn as sns
>>>
Files
Plots
Packages
Help
Viewer
Zoom
Export
tip
total_bill
smoker
Yes
No
A Python REPL opens in the console when you run Python code with a keyboard shortcut. Type exit to close.
matplotlib plots display in plots pane.
Press F1 over a Python symbol to display the help topic for that symbol.

Materiais extras

- Colinha do reticulate
- Documentação completa do reticulate